Resultados y alcance

Informe de recuperación y evaluación del corpus literario

23 de octubre de 2026. Versión v2; benchmark de desarrollo asistido por IA.

Integrantes: Juárez Ramírez Roxana y Reynoso Ortega Valeria

Estado: ejecución técnica completada; aprobación de los juicios de relevancia pendiente. Este documento no acredita una evaluación humana ni una calidad final del buscador. Las métricas se calculan sobre un conjunto de positivos incompleto.

Componente	Resultado
Corpus	300 fragmentos; 33 obras; 27 autores
Benchmark	15 consultas: 5 fáciles, 5 medias y 5 difíciles
Juicios	190 pares con relevancia 1 o 2, cita y justificación
Experimentos	12 configuraciones; 180 rankings; 1800 posiciones
Verificación	900 valores coinciden con el evaluador del profesor

La configuración con mayor nDCG medio observado es **texto + unigramas + frecuencia**: nDCG@10 = 0.1768; P@10 = 0.1533. Es una comparación descriptiva sobre este benchmark, sin prueba de significación ni conjunto externo.

La baseline fijada para el análisis es **texto + unigramas + TF-IDF**: nDCG@10 = 0.1497; P@10 = 0.1400; MRR = 0.3725. No se eligió después de ver qué configuración ganaba.

Cómo se construyó la evaluación

Las consultas y sus juicios se congelaron antes de ejecutar las 12 configuraciones. Se preservan huellas SHA-256 de queries.tsv, qrels.tsv, las evidencias y el corpus. No se cambiaron etiquetas para mejorar las métricas.

La lectura se apoyó en ventanas localizadas mediante términos y variantes, diversificadas por obra. Los patrones solo ofrecieron candidatos: no asignaron puntuación de relevancia ni utilizaron scores VSM. La valoración de Codex (IA) se fundamenta en la cita y su contexto local; no supone revisar exhaustivamente los 4500 pares posibles ni leer de nuevo cada obra completa.

Grado	Criterio operativo
0	Fuera de qrels: no juzgado; se computa como 0 por la convención del ejercicio. No es un negativo confirmado.
1	Alusión breve, contextual o indirecta que aporta parte de la situación solicitada.
2	Evidencia local directa y desarrollada que representa la situación o motivo de la consulta.

Cada consulta tiene entre 12 y 15 positivos y combina grados 1 y 2. Los cinco niveles fáciles buscan objetos o acciones explícitas; los medios describen experiencias; los difíciles exigen interpretar relaciones o motivaciones. Son niveles de diseño, no dificultad empíricamente calibrada.

Sesgo y cobertura: las consultas se diseñaron con conocimiento del corpus. No se copiaron literalmente las consultas de selección, pero algunos temas se solapan y el corpus ya estaba enriquecido por motivos narrativos. No puede afirmarse independencia temática ni generalización externa.

El corpus conserva los 300 fragmentos por decisión del equipo. Los defectos de fuente pendientes no desaparecen al normalizar o evaluar; se mantienen como limitación de esta versión.

Las quince consultas congeladas

ID	Nivel	Consulta	Positivos
Q01	1	Personajes que escriben, reciben o leen una carta.	15
Q02	1	Una conversación o transacción sobre dinero, precios o pagos.	12
Q03	1	Descripción de la ropa o de cómo se viste una persona.	14
Q04	1	Personajes que comen o beben durante una comida.	14
Q05	1	Descripción de una habitación y sus muebles.	13
Q06	2	Una experiencia de enseñanza, aprendizaje o disciplina escolar.	12
Q07	2	Una práctica religiosa influye en la conducta o la experiencia de los personajes.	12
Q08	2	Una persona necesita cuidados por su estado de salud.	14
Q09	2	La música forma parte de una experiencia emocional o social.	12
Q10	2	La apariencia física de alguien provoca una impresión o un juicio sobre esa persona.	12
Q11	3	La subsistencia de una persona depende de la ayuda material de otras.	12
Q12	3	Una persona disimula lo que siente para mantener una apariencia ante los demás.	12
Q13	3	El recuerdo de una experiencia anterior modifica la manera de vivir o comprender el presente.	12
Q14	3	Una diferencia de posición social condiciona la manera de tratar o valorar a alguien.	12
Q15	3	La preocupación por la opinión ajena influye en lo que hace o siente una persona.	12

Los positivos y sus grados se encuentran en qrels.tsv. Las citas, posiciones y justificaciones están en benchmark/juicios_evidencia.tsv.

Comparación de configuraciones

Configuración	P@10	R@10	F1@10	MRR	nDCG@10
titulo_1_frecuencia	0.0600	0.0484	0.0535	0.0970	0.0482
titulo_1_binaria	0.0600	0.0484	0.0535	0.0970	0.0482
titulo_1_tfidf	0.0600	0.0484	0.0535	0.0970	0.0482
titulo_2_frecuencia	0.0600	0.0484	0.0535	0.0970	0.0482
titulo_2_binaria	0.0600	0.0484	0.0535	0.0970	0.0482
titulo_2_tfidf	0.0600	0.0484	0.0535	0.0970	0.0482
texto_1_frecuencia	0.1533	0.1180	0.1331	0.5178	0.1768
texto_1_binaria	0.1333	0.1014	0.1150	0.2467	0.1215
texto_1_tfidf	0.1400	0.1073	0.1213	0.3725	0.1497
texto_2_frecuencia	0.0467	0.0373	0.0414	0.0770	0.0378
texto_2_binaria	0.0467	0.0373	0.0414	0.0770	0.0378
texto_2_tfidf	0.0467	0.0373	0.0414	0.0770	0.0378

Coincidencias nulas: las seis configuraciones de título no encuentran similitud positiva para ninguna consulta. Sus métricas no nulas proceden exclusivamente de completar con ceros y desempatar por ID; no deben interpretarse como recuperación efectiva.

En las tres configuraciones de bigramas del texto, 11 de 15 consultas tampoco tienen coincidencia positiva. Los títulos suelen nombrar obras y personajes, mientras las consultas describen escenas. Los bigramas exigen adyacencias exactas del flujo normalizado; una paráfrasis o una palabra distinta rompe esa coincidencia.

Los resultados iguales entre representaciones no acreditan equivalencia general: aquí pueden compartir un ranking arbitrario de ceros o las mismas escasas coincidencias. Las frecuencias superan a TF-IDF en este experimento; eso no demuestra superioridad universal.

Resultados de la baseline

Consulta	P@10	R@10	F1@10	RR	nDCG@10
Q01	0.4000	0.2667	0.3200	1.0000	0.4046
Q02	0.2000	0.1667	0.1818	0.5000	0.2217
Q03	0.0000	0.0000	0.0000	0.0000	0.0000
Q04	0.3000	0.2143	0.2500	0.5000	0.2581
Q05	0.4000	0.3077	0.3478	1.0000	0.4538
Q06	0.2000	0.1667	0.1818	1.0000	0.3500
Q07	0.0000	0.0000	0.0000	0.0000	0.0000
Q08	0.1000	0.0714	0.0833	0.1111	0.0221
Q09	0.2000	0.1667	0.1818	1.0000	0.3538
Q10	0.0000	0.0000	0.0000	0.0000	0.0000
Q11	0.1000	0.0833	0.0909	0.1667	0.0784
Q12	0.0000	0.0000	0.0000	0.0000	0.0000
Q13	0.1000	0.0833	0.0909	0.1667	0.0261
Q14	0.0000	0.0000	0.0000	0.0000	0.0000
Q15	0.1000	0.0833	0.0909	0.1429	0.0766

P@10: positivos juzgados recuperados / 10. **R@10:** positivos juzgados recuperados / positivos de qrels. **F1@10:** media armónica de P y R. **RR:** inverso de la primera posición relevante del Top-10; su promedio es el MRR aquí calculado, truncado al Top-10. **nDCG@10:** ganancia $2^{\text{relevancia}}-1$ descontada por $\log_2(\text{posición}+1)$, dividida por el ideal.

La media de F1 se obtiene promediando F1 por consulta, no recalculándola desde las medias de P y R. Las métricas agregadas por dificultad están disponibles en metricas_por_nivel.tsv.

Recall se refiere solo a los positivos identificados. Un documento recuperado sin juicio se penaliza como 0 aunque realmente pueda ser relevante; por ello estos valores no estiman la precisión o cobertura real de todo el corpus.

Cinco casos de mejor resultado relativo

Selección por nDCG@10 de la baseline; empate por ID. Los dos grupos no se solapan. “Mejor” y “peor” son relativos a estos quince resultados y estos qrels.

Q05 · Coincidencia de escena y vocabulario

nDCG@10 0.4538 · P@10 0.40. El primer resultado, F0187, describe la acumulación de objetos en el cuarto de Gregorio y está juzgado con 2. F0184, segundo, tiene relevancia parcial. La combinación habitación/muebles coincide con el motivo solicitado. F0225, tercero, menciona un armario: la presencia de un mueble puede elevar un pasaje que no describe extensamente el espacio. El acierto es relativo al qrels y no prueba que los diez resultados sean buenos.

Q01 · Cartas como estructura narrativa

nDCG@10 0.4046 · P@10 0.40. F0112, primero, presenta el incidente de una carta y tiene relevancia 2. F0078 contiene correspondencia explícita. Sin embargo, F0007 aparece segundo y narra que la señora Ramsay escribía cartas: es un candidato relevante no incluido en el qrels congelado. Por tanto, parte de la penalización puede proceder de cobertura incompleta de los juicios, no de un fallo de recuperación. Se debe revisar en una futura versión, sin cambiar retrospectivamente este experimento.

Q09 · Vocabulario musical específico

nDCG@10 0.3538 · P@10 0.20. F0120 ocupa el primer lugar y tiene relevancia 2: Mozart, Hándel, violín y compañía enlazan música y emoción. El VSM aprovecha esos términos, pero no sabe por sí mismo qué función emocional cumplen. Otros resultados de Proust o Hesse no juzgados pueden desarrollar música y vida social. Esta consulta muestra coincidencia léxica útil, además de la necesidad de ampliar la evaluación de los recuperados.

Q06 · Una experiencia de formación reconocible

nDCG@10 0.3500 · P@10 0.20. F0164 aparece primero y está juzgado con 2: clases, profesores y aprendizaje científico sostienen la relevancia. La coincidencia no depende solo del título de Frankenstein. En otras posiciones pueden aparecer menciones educativas o vocabulario genérico que no constituyan una experiencia escolar completa. El resultado permite ilustrar la diferencia entre coincidencia temática directa y alusiones parciales, sin atribuir comprensión semántica al vectorizador.

Q04 · Polisemia y escenas de comida

nDCG@10 0.2581 · P@10 0.30. F0221, segundo, está juzgado con 2 por la selección y consumo de alimentos para evitar un somnífero. El primer resultado, F0021, dice que el personaje se ha bebido prendas: es una metáfora del gasto en alcohol. Esto puede activar comer/beber sin representar una comida. La consulta combina aciertos con ambigüedad léxica; una buena posición relativa no significa que la primera respuesta sea la mejor.

Cinco casos de peor resultado relativo

Selección por nDCG@10 de la baseline; empate por ID. Los dos grupos no se solapan. “Mejor” y “peor” son relativos a estos quince resultados y estos qrels.

Q03 · Un cero no demuestra irrelevancia

nDCG@10 0.0000 · P@10 0.00. El nDCG@10 es cero respecto de los qrels, pero F0117, primero, describe ropa que cuelga de un cuerpo contraído y prendas apretadas. Es un candidato claramente pertinente no juzgado en este benchmark. No puede describirse este caso como fracaso semántico demostrado. La omisión proviene del muestreo de anotación; requiere revisar ese resultado y otros pasajes antes de interpretar el cero como calidad real del sistema.

Q07 · Formulación abstracta y palabras generales

nDCG@10 0.0000 · P@10 0.00. Los primeros resultados son F0268 y F0200, ausentes del qrels de esta consulta. La formulación práctica religiosa/conducta/experiencia no reproduce necesariamente el vocabulario rezar, misa o comunión de los positivos. F0200 trata de un sacerdote, pero la evidencia leída se centra en relaciones domésticas y económicas. Es plausible una combinación de desajuste léxico y menciones incidentales; hace falta juzgar los diez recuperados para separar ambas causas.

Q10 · La relación entre rasgo físico y juicio no es una bolsa de palabras

nDCG@10 0.0000 · P@10 0.00. F0040 y F0017 encabezan la lista, ambos sin juicio para esta consulta. Los positivos incluyen inferir bondad de un rostro (F0036) o atribuir maldad a Hyde por su apariencia (F0111). Palabras amplias como persona, impresión o juicio pueden aparecer en muchos contextos. El VSM no representa explícitamente la relación causal apariencia→valoración. El cero medido no permite, sin cotejo de los recuperados, atribuir todos los fallos a esa limitación.

Q12 · Fingimiento, sentimiento y cobertura de anotación

nDCG@10 0.0000 · P@10 0.00. F0033 encabeza el ranking con alusiones al disimulo y F0005 aparece segundo con dificultad para expresar sentimientos. Son candidatos no juzgados, no negativos confirmados. Los positivos congelados describen actuaciones claras como fingir beber (F0006) o aparentar serenidad (F0083). La formulación abstracta dificulta la coincidencia exacta, pero la falta de juicios sobre los recuperados también explica parte del cero y debe quedar separada del error del sistema.

Q14 · Caso fuerte de cobertura incompleta

nDCG@10 0.0000 · P@10 0.00. F0272, primero, comienza hablando de la clase social de Swann y de una posición excepcional; no figura en los qrels de Q14. F0022, segundo, discute posición, matrimonio y sacrificio económico. Ambos merecen revisión de relevancia. El nDCG cero significa que ninguno de los diez está en el conjunto positivo congelado, no que todos sean irrelevantes. No es defendible usar este cero como evidencia concluyente de que el modelo no capta diferencias sociales.

Cómo reproducir y revisar

Desde la raíz del proyecto, con las dependencias y el modelo de español usados en la normalización:

```
python scripts/10_evaluar_benchmark.py
python scripts/04_auditar_corpus.py --help
python scripts/09_recuperar_fragmentos.py --help
```

La búsqueda de consultas usa las mismas funciones preparar_para_spacy y normalizar_doc del script 05, spaCy 3.8.16 y es_core_news_sm 3.8.0. El manifiesto registra el modelo y la política; las consultas usan esas mismas funciones y transform() en el vectorizador ya ajustado. No se vuelve a entrenar con la consulta.

Archivo o carpeta	Contenido
queries.tsv / qrels.tsv	Benchmark congelado, con los nombres y columnas solicitados.
vectorizacion/manifiesto.json	Metadatos del corpus, modelo y política de normalización.
resultados/<configuración>/rankings.tsv	150 filas: quince consultas con diez documentos y sus scores.
metricas_por_consulta.tsv	180 filas de métricas; una por consulta y configuración.
comparacion_configuraciones.tsv	Promedios de las doce configuraciones.
resultados/consultas/	Salida HTML de consultas ejecutadas con el script 09.
benchmark/juicios_evidencia.tsv	190 juicios con citas y justificaciones.
analisis_errores.json	Los diez casos interpretados en este informe.

Para revisar juicios, conservar esta versión y crear una nueva. No sobrescribir qrels para que los resultados anteriores sigan siendo reproducibles. Registrar qué etiquetas cambian, quién las valida y por qué.

Verificación y cierre pendiente

El evaluador propio coincide, dentro de tolerancia 10^{-12}, con el script del profesor para los 900 valores de métricas por consulta/configuración. Se verificaron 180 rankings y 1800 posiciones, IDs, orden descendente, valores finitos, mezcla de grados y correspondencia exacta de las 190 citas con el corpus.

Las cuatro pruebas del evaluador cubren ranking perfecto, aciertos parciales, ausencia de aciertos, duplicados y benchmark congelado. Esto valida cálculos y trazabilidad; no certifica la exactitud de los juicios de relevancia.

Antes de una entrega definitiva: el equipo debe revisar las etiquetas asistidas por IA y los candidatos relevantes no juzgados, especialmente Q03/F0117 y Q14/F0272. Una nueva versión deberá conservar la separación entre anotación y comparación final. No afirmar que los ceros prueban irrelevancia ni que este benchmark es exhaustivo.

Los 300 fragmentos se mantienen. Las incidencias de fuente siguen documentadas. La última fase está ejecutada como experimento de desarrollo y la entrega mínima integra los metadatos en 05 y 07: quedan resultados, código y un informe con los nombres del equipo, pero la validación humana de relevancia y la decisión académica de cierre no se sustituyen por este documento.

Huellas del experimento

queries.tsv: 946e2eba186d1255626a7590c227fdffca14687b6315aa92be7020c73a6cefd9

qrels.tsv: 1b26605f186456ea15564a241429512cc5e5a616a53f4101c8773831c16d4623

Corpus v2: e94fe3603fb9ba41d9ded0e89bb57977637c710fc8eaec57a476cfad52b6ab28

Las verificaciones se realizaron durante el desarrollo; la entrega mínima conserva solo los scripts de auditoría, sin verificadores independientes de otras fases. El evaluador del profesor se usó como contraste sin modificarlo. Los TSV de muestra no se incorporaron como juicios del corpus.