

Instituto Politécnico Nacional

Escuela superior de cómputo



Project Stage 1

Evaluación de un sistema de recuperación de fragmentos literarios.

Fecha de entrega: 23 de octubre del 2026

Juárez Ramírez Roxana Jimena

Reynoso Ortega Valeria

6am1

1. Resumen ejecutivo

Evaluamos un sistema de recuperación de fragentos literarios basado en respresentaciones vectoriales de términos normalizados y similitud coseno. El experimento consistió en 15 consultas divididas en tre niveles de dificultad y de 12 configuraciones distintas que combinan el campo de búsqueda, la granularidad y el esquema de ponderación.

Para nuestro analísis comparamos los primeros 10 documentos recuperados por cada consulta

Resultados principales

La configuración texto_1_frecuencia fue la que obtuvo el mejor rendiimento, alcanzando un nDCG@10 promedio de 0.1768 y un MRR de 0.5178. Estos valores superan a la configuración de referencia (texto_1_tfidf), que se quedó en un nDCG@10 de 0.1497 y un MRR de 0.3725.

Cabe destacar que esta diferencia es solamente descriptiva, ya que no se aplicaron pruebas de significancia ni de validación extrema.

Problemas observados

Encontramos una ausencia total de coincidencias léxicas en los títulos para las consultas analizadas. Los bigramas de texto también generaron muy pocos aciertos, aunque el uso de unigramas funciona mejor, en ellos persisten retos como la ambigüedad, el vocabulario abstracto y las relaciones narrativas complejas, sin embargo los juicios de relevancia están incompletos y no podemos asegurar que todos los ceros sean errores reales del sistema.

2. Objetivo y material analizado

El objetivo principal es documentar el rendimiento de las distintas representaciones léxicas, para eso seleccionamos las cinco consultas con mejor y peor desempeño para analizar sus posibles causes. La idea es conservar estos casos de estudio y compararlos más adelante con un modelo de búsqueda basado en embeddings.

Revisamos los archivos del benchmark, la guía metodológica, los resultados top-10 de la configuración base y el corpus original sin normalizar, además cruzamos las posiciones de estos 10 casos con el archivo rankings.tsv y leímos los fragmentos en literature_raw_corpus.tsv.

El proceso abarca desde la extracción de los archivos EPUB, su selección y auditoría, la limpieza del texto con spaCy, la vectorización y la busqueda y evaluación.

El corpus contiene 300 fragmentos en español, extraídos de 33 obras y 27 autores.

3. Metodología

Tanto los textos como las consultas se limpian mediante lematización y filtros gramáticales, después evaluamos las representaciones por frecuencia, presencia binaria y TF-IDF, aplicadas a unigramas o bigramas en el trxto y título, cada consulta se ajusta a este vocabulario y se compara utilizando similitud coseno.

El benchmark tiene 5 consultas por cada nivel de dificultad, los aciertos se evalúan con relevancia directa grado 2 o parcial grado 1.

Para medir el desempeño calculamos P@10, F1@10, RR, MRR y nDCG@10.

Un punto importante es que los documentos ausentes en los qrels se consideraron como 0 solo para hacer los cálculos, lo que no necesariamente significa que sean irrelevantes.

Para seleccionar los diez casos de análisis tomamos los cinco puntajes más altos y los cinco más bajos de nDCG@10 y utilizamos query_id para desempatar y evitar repeticiones.

Control de consistencia independiente

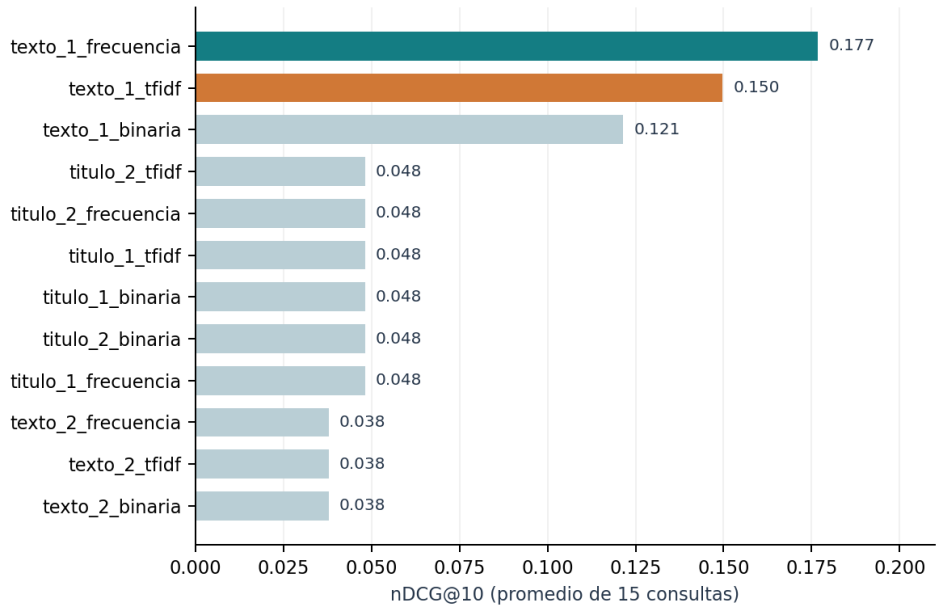
Para validar los datos, recalculamos las métricas P@10, RR y nDCG@10 a partir de los 150 resultados de rankings.tsv y los 190 pares de qrels.tsv, los resultados coindiden con el archivo metricas_por_consulta.tsv, solo con pequeñas diferencias de redondeo.

Confirmamos que los 150 documentos recuperados existen en el corpus, 21 tieen un juicio de relevancia y 129 no.

Finalmente, aunque el archivo de ranking no indica explícitamente su configuración, sus valores replican las métricas de texto_1_tfidf.

4. Comparación global de configuraciones

Las 3 representaciones que utilizan unigrmas en el texto obtienen los mejores promedios. Aqune la ponderación por frecuencia supera a TF-IDF en este benchmark, no podemos afirmar que sea siempre superior, esto se debe a que la muestra de apenas 15 consultas y la cobertura de los juicios de la evaluación está incompleta.



Configuración	P@10	R@10	F1@10	nDCG@10	MRR
texto_1_frecuencia	0.153	0.118	0.133	0.177	0.518
texto_1_tfidf	0.140	0.107	0.121	0.150	0.372
texto_1_binaria	0.133	0.101	0.115	0.121	0.247
titulo_1_frecuencia	0.060	0.048	0.054	0.048	0.097
titulo_2_frecuencia	0.060	0.048	0.054	0.048	0.097
titulo_1_tfidf	0.060	0.048	0.054	0.048	0.097
titulo_1_binaria	0.060	0.048	0.054	0.048	0.097
titulo_2_tfidf	0.060	0.048	0.054	0.048	0.097
titulo_2_binaria	0.060	0.048	0.054	0.048	0.097
texto_2_frecuencia	0.047	0.037	0.041	0.038	0.077
texto_2_binaria	0.047	0.037	0.041	0.038	0.077
texto_2_tfidf	0.047	0.037	0.041	0.038	0.077

La mejor configuración obtuvo un P@10 de 0.1533, lo que significa que encuentra en promedio, 1.53 resultados relevantes por cada diez, la configuración base de texto_1_tfidf se queda un poco atrás con 0.1400 y por el otro lado, las seis variantes que buscan en el título quedan con un puntaje muy bajo de 0.0482 nDCG@10, al igual que las 3 opciones que usan bigramas de texto con resultados de 0.0378. En las seis configuraciones de título, las 15 consultas tuvieron similitud coseno cero; sus métricas no nulas proceden del desempate por ID, no de coincidencias positivas. En cada configuración de bigramas del texto, 11 de las 15 consultas tampoco tuvieron coincidencias positivas.

5. Rendimiento según nivel de consulta

Comparamos los promedios por nivel entre la mejor configuración general y la de referencia, cabe aclarar que estos “niveles” son categorías diseñadas para organizar el benchmark, no una medida absoluta y universal de dificultad.

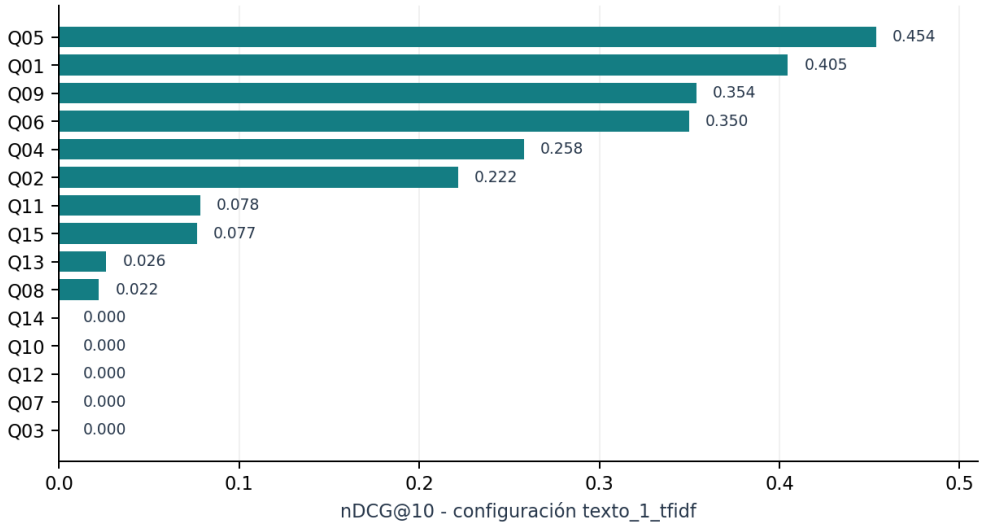
Configuración	Nivel	P@10	nDCG@10	MRR
texto_1_frecuencia	1	0.300	0.326	0.800
texto_1_frecuencia	2	0.100	0.139	0.467
texto_1_frecuencia	3	0.060	0.066	0.287

texto_1_tfidf	1	0.260	0.268	0.600
texto_1_tfidf	2	0.100	0.145	0.422
texto_1_tfidf	3	0.060	0.036	0.095

Se notó que el rendimiento nDCG@10 baja al pasar del nivel 1 al 3, esto tiene sentido porque las consultas más avanzadas exigen interpretar conceptos más abstractos, sin embargo, no podemos asegurar que esta sea la única razón, ya que la caída también podría deberse a que hay menos juicios de evaluación disponibles en esos niveles.

6. Selección de los 10 casos

Para elegir los casos ordenamos las consultas según en nDCG@10 obtenido en la configuración base. Hblar de un mejor o peor desempeño es relativo: solo describe el puntaje numérico, no significa que el sistema haya respondido de forma perfecta.



Grupo con mejor desempeño

Consulta	nDCG@10	Explicación
Q05	0.4538	Recuperó 4 fragmentos relevantes entre los primeros 10 y el primero tenía alta relevacia.
Q01	0.4046	Ecnontró 4 resultados relevantes, incluyendo uno en la primera posición relacionados con cartas y correspondecia.

Q09	0.3538	Aunque solo recuper+o 2 resultados relevamtes, uno apareció en primer lugar y presentó una relación directa con la música.
Q06	0.3500	Recuperó 2 resultados relevantes y el primero describía una experiencia de enseñanza y aprendizaje.
Q04	0.2581	Recuper+o 3 resultados relevantes, pero el primero apareció en segunda posición.

Estas consultas obtuvieron valores más altos de nDCG@10 y en general lograron recuperar fragmentos relevantes en las primeras posiciones, también en algunos casos observamos como el sistema pudo aprovechar coincidencias de vocabulario relacionadas directamente con el tema buscado.

Grupo con peor desempeño: Q03, Q07, Q10, Q12 y Q14.

Estas cinco consultas obtuvieron un nDCG@10 de 0, porque ninguno de sus primeros diez resultados coincidió con los fragmentos registrados como relevantes en los juicios de evaluación.

Algunas consultas necesitan identificar relaciones más complejas, pero al revisar los textos originales encontramos que algunos resultados sí podían responder a las consultas, aunque no estaban incluidos en los jucios de relevancia.

Por ejemplo Q03, cuyo primer fragmento describe vestimenta y Q14, que recuperó un pasaje relacionado con la posición social, o sea que sus puntuaciones bajas no necesariamente representan errores completos del sistema, sino que también reflejan las limitaciones del conjunto de evaluación.

La selección de casos nos permite reconocer y estudiar las fortalezas y debilidades de nuestro modelo de recuperación léxica, las consultas con las mejores puntuciones nos favorecen la recuperación, mientras que las de menor puntuación nos permiten analizar posibles problemas de ambigüedad, falta de coincidencia léxica y cobertura incompleta de los juicios.

7. Cinco consultas con mejor desempeño relativo

Analizamos cómo le fue a cada una de estas consultas usando la configuración de referencia, es importante recordar que un puntaje alto sigue siendo relativo y la lista de resultados aún puede contener errores o fragmentos que nadi ha evaluado.

Q05 · Coincidencia de escena y vocabulario.

Consulta: Descripción de una habitación y sus muebles.
Nivel: 1 P@10: 0.400 R@10: 0.308 nDCG@10: 0.454 RR: 1.000

El sistema acertó al encontrar textos que describen espacios y muebles (el fragmento F0187 es muy relevante y el F0184 lo es en parte). Usar un vocabulario tan específico ayuda al buscador, aunque a veces se confunde: mencionar un "armario" (como en F0225) no significa que se esté describiendo toda la habitación.

Diagnóstico principal: Éxito gracias a palabras muy específicas, solo con un ligero riesgo de traer textos incompletos.

Q01 · Cartas como estructura narrativa

Consulta: Personajes que escriben, reciben o leen una carta.
Nivel: 1 | P@10: 0.400 | R@10: 0.267 | nDCG@10: 0.405 | RR: 1.000

Los mejores resultados (F0112 y F0078) hablan directamente de correspondencia. El sistema también encontró en segundo lugar un texto (F0007) donde un personaje escribe cartas; aunque el buscador hizo un buen trabajo, sus calificaciones bajan artificialmente porque ese fragmento aún no había sido validado por los evaluadores humanos.

Diagnóstico principal: Acertó por las palabras clave, pero las métricas lo penalizan injustamente por falta de evaluación manual previa.

Q09 · Vocabulario musical específico

Consulta: La música forma parte de una experiencia emocional o social.
Nivel: 2 | P@10: 0.200 | R@10: 0.167 | nDCG@10: 0.354 | RR: 1.000

El mejor resultado (F0120) es muy preciso y menciona a Mozart, Händel y un violín. Estas palabras clave ayudan mucho, pero revelan un límite: el sistema sabe

encontrar términos musicales, pero no entiende realmente si esa música está causando una emoción o un impacto social en la historia.

Diagnóstico principal: Se apoya bien en palabras sobre música, pero no comprende el contexto emocional o social.

Q06 · Una experiencia de formación reconocible

Consulta: Una experiencia de enseñanza, aprendizaje o disciplina escolar.
Nivel: 2 | P@10: 0.200 | R@10: 0.167 | nDCG@10: 0.350 | RR: 1.000

El primer resultado (F0164) es un éxito total porque describe una escena clara de clases, profesores y aprendizaje. El buscador es muy bueno identificando vocabulario escolar concreto, pero corre el riesgo de traer textos donde la educación solo se menciona de pasada.

Diagnóstico principal: Éxito al encontrar vocabulario educativo, aunque podría confundirse con menciones superficiales.

Q04 · Polisemia y escenas de comida

Consulta: Personajes que comen o beben durante una comida.
Nivel: 1 | P@10: 0.300 | R@10: 0.214 | nDCG@10: 0.258 | RR: 0.500

Hay aciertos reales, como el segundo resultado (F0221) que describe una comida. Sin embargo, el primer lugar (F0021) es un error: usa la palabra "beber" en sentido figurado, no literal. Esto demuestra que las palabras con doble significado confunden al sistema.

Diagnóstico principal: Mezcla aciertos literales con errores causados por palabras de doble sentido (polisemia).

8. Las cinco consultas con peor desempeño

En estas búsquedas, todas las métricas de éxito (nDCG@10, P@10, RR) marcan cero, sin embargo, esto no siempre significa que el sistema falló por completo; muchas veces encontró buenos textos que simplemente no han sido revisados apropiadamente.

Q03 · Un cero no demuestra irrelevancia

Consulta: Descripción de la ropa o de cómo se viste una persona.
Nivel: 1 | P@10: 0.000 | R@10: 0.000 | nDCG@10: 0.000 | RR: 0.000

Aunque las métricas marcan cero, el primer resultado que arrojó el sistema (F0117) sí describe cómo le queda la ropa a un personaje. El problema es que este texto no estaba en la lista de revisión humana. El sistema hizo un buen trabajo que las matemáticas no supieron reconocer.

Diagnóstico principal: El puntaje de cero es engañoso; el sistema encontró un texto correcto que falta por evaluar.

Q07 · Formulación abstracta y palabras generales

Consulta: Una práctica religiosa influye en la conducta o la experiencia de los personajes.

Nivel: 2 | P@10: 0.000 | R@10: 0.000 | nDCG@10: 0.000 | RR: 0.000

Los dos primeros resultados parecen ser errores del sistema. Uno (F0268) habla del efecto emocional de leer novelas, y el otro (F0200) menciona a un capellán pero hablando de temas administrativos, no religiosos. Como la consulta es tan abstracta, el sistema se confunde con coincidencias de palabras aisladas.

Diagnóstico principal: Las palabras clave no logran captar un tema tan abstracto y el sistema trae textos irrelevantes.

Q10 · La relación entre rasgo físico y juicio no es una bolsa de palabras

Consulta: La apariencia física de alguien provoca una impresión o un juicio sobre esa persona.

Nivel: 2 | P@10: 0.000 | R@10: 0.000 | nDCG@10: 0.000 | RR: 0.000

Los dos primeros resultados son casos muy distintos. El primero (F0040) es un acierto no reconocido: un personaje deduce la falta de afecto de una mujer por su mal aspecto. El segundo (F0017) es un error por doble sentido: usa la frase "en apariencia" para describir una ciudad, no a una persona.

Diagnóstico principal:Mezcla un resultado correcto que falta por evaluar, con un claro error por palabras de doble sentido.

Q12 · Fingimiento, sentimiento y cobertura de anotación

Consulta: Una persona disimula lo que siente para mantener una apariencia ante los demás.

Nivel: 3 | P@10: 0.000 | R@10: 0.000 | nDCG@10: 0.000 | RR: 0.000

El primer resultado (F0033) es un error: habla de un engaño sobre hechos ("un genio del disimulo"), pero no sobre ocultar sentimientos. El segundo (F0005) es mucho mejor: un personaje se aguanta las ganas de quejarse para no molestar a su esposa que podría ser útil (revisión pendiente).

Diagnóstico principal: El sistema no distingue bien entre mentir sobre hechos y ocultar emociones, pero aun así encontró un texto útil no evaluado.

Q14 · Caso fuerte de cobertura incompleta
Consulta: Una diferencia de posición social condiciona la manera de tratar o valorar a alguien.
Nivel: 3 | P@10: 0.000 | R@10: 0.000 | nDCG@10: 0.000 | RR: 0.000

El primer resultado (F0272) analiza el prestigio y la clase social de un personaje; es claramente un texto útil que simplemente no ha sido evaluado. El segundo (F0022) habla de matrimonios por conveniencia económica, lo cual está relacionado, pero no responde tan directamente a cómo el estatus afecta el trato personal.

Diagnóstico principal: El sistema encontró un texto excelente que las métricas ignoran por falta de validación manual.

9. Diagnóstico general de errores

Búsqueda por títulos:
Fue un fracaso, usar el título para buscar no es muy efectivo porque el título de una obra no describe cada escena que ocurre dentro del libro.

Búsqueda por bigramas:
Fue demasiado estricta, exigir que el buscador encuentre dos palabras exactamente juntas limitó mucho los resultados, al hablar o escribir, la gente formula las mismas ideas de maneras diferentes.

Búsqueda por unigramas:
Encontró demasiados textos, pero muy pocos eran realmente útiles, esto nos confirma que no porque un texto tenga las mismas palabras que la búsqueda significa que la escena trata de eso.

Normalización:
El proceso de simplificar las palabras dejando solo raíces y borrando términos comúnes, ayuda a encontrar más coincidencias, pero correl el riesgo de borrar palabras que le daban sentido a la frase, admás tuvimos errores, como la palabra “comar” que hay que revisar.

10. Limitaciones del estduio y cosas por mejorar

Faltan evaluaciones para la mayoría de los resultados:
De los 150 mejores fragmentos que arrojó el sistema, 129 no tienen una calificación que nos diga si sirvieron o no y las calificaciones que sí existen se hicieron con ayuda de Codex.

Es difícil interpretar si el sistema acertó:
Se comprobó que el sistema funciona técnicamente bien (no inventa textos y los ordena correctamente), sin embargo, para saber si un texto realmente responde a lo que se buscaba, se necesita que una persona lo lea con detenimiento, sobre todo porque en la literatura muchas cosas dependen del contexto de la historia.
Pocas búsquedas de prueba:
Como este estudio solo analizó 15 consultas, nos da una buena idea de cómo se comporta el sistema en estos casos, pero no podemos garantizar que vaya a funcionar igual de bien para cualquier otra búsqueda literaria.

Lo que se debe hacer antes de avanzar:
Antes de comparar este buscador básico con un sistema de IA más avanzado (basado en embeddings), es indispensable que personas lean y califiquen los textos que todavía no tienen nota.

11. Protocolo de comparación furuta con embeddings.

Para que la proxima prueba sea justa guardaremos 10 búsquedas específicas, Q05, Q01, Q09, Q06, Q04, Q03, Q07, Q10, Q12 y Q14 exactamente como están, para poder comparar este sistema como uno nuevo, es obligatorio que ambos busquen en los mismos textos y se midan con las mismas reglas.

Etapa	Control de comparabilidad
Congelar entradas	Versionar corpus, consultas, qrels e identificar qué preprocesamiento corresponde a cada sistema.
Recuperar	Generar rankings con identificadores, posiciones y puntuaciones, sin modificar las consultas después de conocer los resultados.
Revisar juicios	Realizar evaluación humana y ciega del Top-10 combinado para corregir la cobertura de qrels.
Comparar	Calcular P@10, R@10, MRR y nDCG@10 bajo el mismo estándar de relevancia.
Explicar cambios	Estudiar sinónimos, metáforas, términos abstractos, relaciones causales y falsos positivos semánticos.

Hipótesis a contrastar: Creemos que los sistemas avanzados “embeddings” pueden entender ideas y conceptos, incluso si el texto no tiene las palabras exactas de búsqueda.

Aunque que no podemos dar por hecho que la IA será mejor por arte de magia. Al intentar conectar ideas, este tipo de tecnología también puede confundirse y juntar situaciones que superficialmente se parecen, pero realmente no tienen nada que ver.

12. Conclusiones

Podemos concluir que buscar por unigramas dio los mejores resultados, mientras que usar títulos o bigramas no fue muy efectivo, aunque el sistma logró aciertos claros se confunde facilmente con el sentido figurado y califica con ceros a textos muy útiles, simplemente porque carecen de una evaluación manual.
El mayor aporte de este estudio es dejar diez búsquedas documentadas como referencia, pero antes de competir contra una IA avanzada, es necesario que personas reales califiquen los textos faltantes para que las futuras comparaciones sean justas.